



INSTITUTO DE
INVESTIGACIONES
SOCIALES

ANÁLISIS MULTIVARIADO

Tipologías políticas en datos

Una introducción al análisis multivariado

Dra. Mónica Lara Escalante
Instituto de Investigaciones Sociales · UNAM
monica.lara@sociales.unam.mx

Agenda

01 Motivación

Tipologías y análisis multivariado en ciencias sociales

02 Análisis de conglomerados

Jerárquico, k-means y elección del número de grupos

03 Análisis de correspondencias

CA simple y múltiple (MCA): geometría de lo categórico

04 Práctica en R

Tras el descanso: script con datos reales

¿Por qué clasificar?

“An intelligent being cannot treat every object it sees as a unique entity unlike anything else in the universe. It has to put objects in categories so that it may apply its hard-won knowledge about similar objects encountered in the past to the object at hand.”

— Pinker (1997), citado en Everitt & Hothorn (2011)

● Clasificar es fundamental

Operación cognitiva primitiva: agrupar objetos similares para predecir y actuar.

● Atajo informativo

Una buena tipología comunica muchas propiedades a la vez, no solo una.

● Herramienta científica

En ciencias sociales: estructurar datos complejos en clases interpretables.

¿Por qué análisis multivariado?

Cuando observamos muchas variables simultáneamente, el ojo humano no alcanza. Las técnicas multivariadas buscan descubrir estructuras latentes (grupos, ejes, oposiciones) que no son visibles desde una sola variable o un cruce bivariado.

1 VARIABLE

Distribución

Frecuencias, histograma

2 VARIABLES

Cruce

Tabla de contingencia, scatterplot

p VARIABLES

Estructura


Clusters, ejes, tipologías

Hoy: dos familias. Conglomerados para datos numéricos; correspondencias para datos categóricos.

La idea fundamental

Cluster analysis es un término genérico para métodos numéricos que buscan descubrir grupos de observaciones homogéneos entre sí y separados de otros grupos.

En 2D el ojo lo hace solo (figura a la derecha).
En p dimensiones necesitamos un criterio formal: distancia entre individuos y regla para fusionar/separar grupos.



Everitt & Hothorn (2011, cap. 6)

La distancia

Todo método de clustering descansa sobre una métrica de cercanía entre individuos. La más común para datos continuos es la distancia euclidiana:

$$d(i, j) = \sqrt{\sum_k (x_{ik} - x_{jk})^2}$$

● La escala importa

Si una variable tiene varianza 23 y otra 582 000 (datos de criminalidad EE.UU.), la segunda domina la distancia. Hay que estandarizar antes de calcular distancias.

● La elección de métrica importa

Existen alternativas: Manhattan, Mahalanobis, chi-cuadrado (para perfiles), distancias para datos binarios o mixtos. Cada una define una geometría distinta.

Tres familias de métodos

JERÁRQUICO

Aglomerativo

Empieza con cada caso como su propio grupo y fusiona iterativamente los más cercanos. Produce una jerarquía completa: el dendrograma.

single / complete / average / Ward

PARTICIONAL

K-means

Parte de k centroides y asigna cada caso al más cercano, recalculando hasta converger. Requiere fijar k de antemano.

minimiza la SS intra-grupo

MODELO

Model-based

Asume una mezcla de distribuciones (típicamente normales multivariadas). Aporta criterios estadísticos para elegir el número de grupos.


mclust, EM, BIC

Jerárquico aglomerativo

Algoritmo

- 1 Cada caso es su propio grupo (n grupos)
- 2 Calcular distancias entre todos los pares
- 3 Fusionar el par más cercano
- 4 Repetir hasta que todo esté en un solo grupo

Resultado: una jerarquía completa. Cortando el árbol a una altura, obtenemos la partición deseada.



Métodos de vinculación entre grupos

Al fusionar, necesitamos una regla para medir la distancia entre dos grupos. Las cuatro principales:

Simple (single linkage)

$$d(A,B) = \min d(i,j), i \in A, j \in B$$

Distancia mínima entre pares. Tiende al “chaining”: cadenas largas y poco compactas.

Completa (complete linkage)

$$d(A,B) = \max d(i,j)$$

Distancia máxima entre pares. Produce grupos compactos y bien separados.

Promedio (average linkage)

$$d(A,B) = (1/n_a n_b) \sum d(i,j)$$

Promedio de todas las distancias entre pares. Compromiso entre simple y completa.

Ward (varianza mínima)

minimiza ΔSS al fusionar

Fusiona los grupos cuya unión incrementa menos la SS intra. Similar en espíritu a k-means.

K-means

Partir los n individuos en k grupos minimizando la suma de cuadrados intra-grupo (WGSS):

$$WGSS = \sum_l \sum_{i \in G_l} \|x_i - \bar{x}_l\|^2$$

Como enumerar todas las particiones es imposible (con $n=25$ y $k=8$ hay $> 6 \cdot 10^{17}$), se usa un algoritmo heurístico iterativo que converge a un óptimo local.

Algoritmo iterativo

- 1 Elegir k centroides iniciales (aleatorios)
- 2 Asignar cada caso al centroide más cercano
- 3 Recalcular los centroides como medias de los grupos
- 4 Repetir 2–3 hasta que ningún caso cambie de grupo


Repetir con varias semillas: el resultado depende del punto de partida.

¿Cuántos grupos? El método del codo

No existe una regla única para elegir k . El método del codo (elbow) es la herramienta práctica más usada:

- Calcular WGSS para $k = 1, 2, 3, \dots$
- Graficar WGSS frente a k
- Identificar el “codo”: punto donde añadir grupos ya no reduce sustancialmente la SS

Las consideraciones aplicadas (interpretabilidad, número manejable de grupos) suelen pesar más que un criterio puramente estadístico.



Buenas prácticas y limitaciones

Buenas prácticas

- Estandarizar variables si están en escalas distintas
- Probar con varias semillas (k-means) y verificar estabilidad
- Comparar resultados de jerárquico, k-means y model-based
- Interpretar grupos con variables externas (validación cualitativa)
- Visualizar en el plano de las dos primeras componentes principales

Limitaciones

- K-means asume grupos esféricos y de tamaño similar
- Sensibilidad a outliers (sobre todo k-means y vinculación simple)
- El resultado depende de la elección de distancia y de la escala
- Siempre encuentra grupos, incluso en datos homogéneos
- No hay un “número correcto” de grupos: criterio del analista

Tasas de criminalidad en EE.UU. (1986)

Datos del Statistical Abstract of the USA (1988): tasas por 100 000 habitantes para 7 tipos de delito en los 50 estados + DC.

Variables

Murder · Rape · Robbery · Assault · Burglary · Theft · Vehicle

Hallazgos

- DC es un outlier extremo (tasa de homicidio = 31)
- Varianzas muy distintas → es indispensable estandarizar
- El método del codo sugiere $k = 2$
- La separación opera sobre la primera componente principal

Varianzas (antes / después de estandarizar)

Variable	Antes	Después
<i>Murder</i>	23	0.026
<i>Rape</i>	212	0.057
<i>Robbery</i>	18 993	0.034
<i>Assault</i>	22 004	0.054
<i>Burglary</i>	177 913	0.053
<i>Theft</i>	582 813	0.064
<i>Vehicle</i>	50 007	0.065

Tasas de criminalidad en EE.UU. (1986)




Fig. 6.10. Plot of k -means two-group solution for the standardised crime rate data.

Y si las variables son categóricas?

Hasta aquí: individuos descritos por variables numéricas, agrupados según distancia euclidiana.

Pero gran parte de los datos de las ciencias sociales son categóricos: género, ocupación, partido, preferencia, opinión. No hay una “distancia euclidiana” natural entre Norway y France, ni entre “muy de acuerdo” y “neutral”.

El análisis de correspondencias responde: ¿cómo representar geométricamente las asociaciones de una tabla de contingencia?

¿Qué es el análisis de correspondencias?

Técnica geométrica para analizar tablas de contingencia. Convierte filas y columnas de la tabla en puntos en un espacio de pocas dimensiones, preservando lo esencial de las asociaciones.

I

Sintetiza

Reduce una tabla $I \times J$ a un mapa de dos o tres dimensiones que capta la mayor parte de la información.

II

Es simétrico

Trata filas y columnas con la misma lógica. Filas y columnas viven en el mismo espacio.

III

Es exploratorio

No requiere modelos previos ni supuestos distribucionales. Descubre estructuras latentes.

Perfiles, masas y baricentro

1

Perfil

Distribución condicional de una fila (o columna). El perfil de Norway sobre los tipos de sociedad es el vector de proporciones [.119, .260, .621].

2

Masa (peso)

La proporción de la tabla que representa esa categoría. Una categoría rara tiene poco peso; una frecuente, mucho.

3

Baricentro (G)

Punto medio ponderado de la nube. Representa el “perfil promedio”. Las distancias se miden respecto a él.

Distancia chi-cuadrado e inercia

Distancia entre perfiles

$$d^2(i, i') = \sum_j (a_{ij} - a_{i'j})^2 / c_j$$

Distancia euclidiana ponderada por la masa de cada categoría.
Penaliza más las diferencias en categorías poco frecuentes.


Inercia (ϕ^2)

$$\phi^2 = \chi^2 / N = \sum_i r_i \cdot d^2(i, G)$$

Suma de las distancias al cuadrado al baricentro, ponderadas por las masas. Es χ^2 normalizada y mide la asociación total de la tabla.

La inercia es a CA lo que la varianza es a PCA: cuanto mayor, más estructurada la nube.

Cómo leer un biplot



Cuatro reglas


- 1 Cercanía entre puntos del mismo conjunto = perfiles similares
- 2 Cuidado con la cercanía fila–columna: solo informativa si ambos puntos están bien representados
- 3 Categorías con contribución $> 1/K$ son las “explicativas” del eje
- 4 $\cos^2$ alto = el eje describe bien la posición de ese punto

Percepciones sociales (ISSP)

ISSP 2009, Social Inequality IV. Tabla: 20 países × 5 tipos de sociedad (de A “pirámide jerárquica” a E “invertida”).

Resultados

- $\chi^2 = 7\,020$, Cramér's $V = 0.42$
- Eje 1 (93%): egalitario ↔ jerárquico
- Eje 2 (5%): contraste entre percepciones jerárquicas
- Noruega y Dinamarca en oposición a Hungría y Polonia



Hjellbrekke (2019), cap. 2 · ISSP 2009 Social Inequality IV

De CA a Análisis Múltiple (MCA)

Cuando tenemos más de dos variables categóricas (típicamente: encuesta con Q preguntas), CA simple no basta. MCA es la generalización natural.

Matriz indicadora binaria

Filas = individuos. Columnas = todas las categorías de todas las variables. Cada celda vale 1 si el individuo eligió esa categoría, 0 si no.

Distancias entre individuos: las crean las preguntas en las que difieren. Cuanto más rara la categoría compartida, más cerca quedan dos individuos que la eligen.

Dos nubes simultáneas

- **Nube de categorías**
interpretamos los ejes y las oposiciones entre modalidades
- **Nube de individuos**
estudiamos heterogeneidad, sub-grupos, elipses de concentración

Características

1. Muestra relaciones entre categorías de variables (no sólo entre variables)
2. No requiere cumplir supuestos (por ejemplo: normalidad)
3. Permite trabajar con múltiples variables
4. Ofrece una forma de análisis (visual) sencilla y eficaz
5. Evitar: datos faltantes, negativos, atípicos
6. Preferir: datos con una misma escala*
7. No ofrece significancia estadística

El propósito de la sociología reflexiva


149

Quine ha desarrollado su idea fundamental).⁴⁶ Y lo que es cierto para los conceptos es cierto para las relaciones, que sólo adquieren su significado dentro de un sistema de relaciones. Del mismo modo, si yo hago un uso amplio del análisis de correspondencias, prefiriéndolo por ejemplo a la regresión multivariada, es porque el análisis de correspondencia es una técnica relacional de análisis de datos cuya filosofía se corresponde exactamente, a mi modo de ver, con aquello que es la realidad del mundo social. Se trata de una técnica que "piensa" en términos de relación, precisamente como yo intento hacerlo con la noción de campo.⁴⁷

Bourdieu, P. Una invitación a la sociología reflexiva

Bordieu P.

- Síntesis analítica de diversos trabajos donde se utilizaron análisis de correspondencias
- Muestra, teóricamente, la organización del espacio social en Francia
- Los ejes se refieren a distintos tipos de capitales



Rescapitulación: ¿cuándo usar qué?

	Datos	Pregunta típica	Salida
Clúster	Numéricos (estandarizados)	¿Existen grupos naturales?	Asignación + dendrograma / centroides
CA simple	Tabla 2 vars. categóricas	¿Qué asocia filas con columnas?	Mapa de filas y columnas
MCA	Q vars. categóricas (encuesta)	¿Qué ejes estructuran las respuestas?	Nube de categorías + de individuos

Todas estas técnicas son exploratorias: sirven para describir estructuras, no para confirmarlas. La interpretación sustantiva sigue siendo trabajo del investigador.

Lecturas de la sesión

CLÚSTER

Everitt, B. & Hothorn, T. (2011). An Introduction to Applied Multivariate Analysis with R. Springer. Cap. 6.

CLÚSTER

Bruce, P., Bruce, A. & Gedeck, P. (2022). Estadística práctica para ciencia de datos con R y Python. O'Reilly. Cap. 7.

CA / MCA

Hjellbrekke, J. (2019). Multiple Correspondence Analysis for the Social Sciences. Routledge. Caps. 2–3.

CA / MCA

Le Roux, B. & Rouanet, H. (2011). Multiple Correspondence Analysis. SAGE QASS Series. Cap. 3.



Práctica en R

Paquetes que usaremos

cluster

factoextra

FactoMineR

ca

ggplot2